Trabajo Final Integrador

Predicción del uso de arma en robos de la Ciudad de Buenos Aires para priorizar el patrullaje preventivo

Diplomatura en Ciencia de Datos y Análisis Avanzado
Proyecto Final Integrador

Equipo: Grupo 29

Integrantes:

Carlos Amigo

Vanina Rieznik

Luis Cortez

Octubre de 2026

Repositorio de código: https://github.com/charlyfriend68/DiploData

1. Resumen ejecutivo

Problema. La Ciudad de Buenos Aires dispone de recursos de patrullaje limitados. Los robos con arma son los más graves y su proporción cambia mucho según el territorio y la hora. La decisión operativa es: ¿en qué combinaciones comuna × franja horaria (15 × 24 = 360 celdas) conviene concentrar la presencia preventiva?

Solución. A partir de 587.192 robos utilizables (de 592.817 registrados) entre 2016 y 2025 se construyó un sistema de priorización que usa solo información disponible antes del hecho (zona, hora, día, mes e historial de la celda). Se compararon cinco modelos (Regresión Logística, Random Forest, XGBoost, LightGBM y una red neuronal) contra reglas simples sin aprendizaje automático, con validación estrictamente temporal y la misma regla de evaluación para todas las estrategias.

Resultados clave.

- Priorizar el 20 % de las celdas (72 de 360) cubre cerca del 52 % de los 8.878 robos con arma del período de prueba. Elegirlas al azar cubriría 20,0 %; elegirlas por volumen total de robos, 39,8 %.
- La mejor regla simple, «seguir los robos armados de los últimos 12 meses», ya cubre 51,7 %. El modelo de control (Regresión Logística × volumen) cubre 52,2 %: +0,47 pp, IC95 [+0,02; +0,92]. La mejora es marginal y no es robusta: actualizando el ranking cada mes, la diferencia es +0,11 pp, indistinguible de cero.
- A nivel de cada robo, la discriminación es moderada (ROC-AUC 0,69; PR-AUC 0,24 contra 0,11 del azar) y es la misma para los cinco modelos y para la regla de tasa histórica de 12 meses. La red neuronal no aporta valor y es 26 veces más lenta que la Regresión Logística.

Recomendación. El valor está en la decisión (ordenar celdas por cantidad esperada de robos armados), no en la complejidad del modelo. Se recomienda operar con el ranking de armados de los últimos 12 meses, actualizado cada mes, y usar la Regresión Logística calibrada × volumen como alternativa de control, explicable y auditable. Antes de escalar, medir el efecto real del patrullaje con un piloto con zonas de control.

2. Definición del problema y relevancia

Contexto y motivación. El patrullaje preventivo es un recurso escaso: no se puede cubrir toda la ciudad a toda hora. Un criterio explícito y auditable para asignarlo mejora la eficiencia y permite explicar las decisiones. La hipótesis de trabajo, apoyada en la experiencia de un integrante del equipo en el ministerio de seguridad de CABA, es que concentrar la presencia en pocos lugares y momentos puede reducir el delito; este informe no lo demuestra (sección 6).

Objetivo medible y KPI. Seleccionar el 20 % de las combinaciones comuna × franja que maximice la **cobertura** de robos con arma, es decir, la proporción de robos armados ocurridos en las celdas priorizadas, evaluada sobre un período futuro que el modelo no vio. KPIs secundarios: ROC-AUC y PR-AUC (por la asimetría de clases), recall por comuna (equidad) y estabilidad temporal.

Hipótesis y veredicto.

- **H1:** hay estructura predecible en el riesgo por zona y hora. **Confirmada**, aunque concentrada en el historial de cada celda.
- **H2:** un modelo flexible supera al promedio histórico. **No confirmada**: ROC-AUC y PR-AUC no se distinguen de la regla simple.
- **H3:** combinar P(arma | robo) con el volumen es mejor que usar solo la probabilidad. **Confirmada**: 52,2 % contra 45,1 %. Pero esa combinación solo supera de forma marginal a la regla simple de armados de 12 meses.

Restricciones. Solo datos agregados y anónimos; sin información previa al hecho más allá de zona, calendario e historial; decisión humana final; resultados explicables para un equipo no técnico.

Valor esperado. En el período de prueba (522 días) hubo 8.878 robos con arma: cada punto porcentual de cobertura equivale a unos 89 robos armados (8.878 / 100 ≈ 88,8). Cubrir 52 % en lugar de 20 % significa concentrar la presencia donde ocurren unos 2.840 robos armados más (32 pp × 88,8 ≈ 2.841), no 2.860. En cambio, la ventaja sobre la regla simple equivale a unos 42 robos armados en 522 días con ranking fijo (+0,47 pp × 88,8 ≈ 41,7) y unos 10 con ranking mensual (+0,11 pp × 88,8 ≈ 9,8). Cobertura no es lo mismo que delitos evitados: ese efecto requiere un diseño causal.

3. Datos y metodología

3.1 Fuente y calidad de los datos

Se usaron los archivos públicos de delitos de la Ciudad (2016–2025): 1.387.622 registros, de los cuales 592.817 son robos (42,7 %). Se descartó el 0,9 % de los robos (5.625) por falta de comuna (0,80 %) o de franja (0,16 %); su tasa de arma (17,0 %) es similar a la del resto (18,4 %), por lo que el descarte no sesga el resultado. Quedaron 587.192 robos utilizables; todas las filas tienen cantidad = 1.

Conclusiones del análisis exploratorio.

- Los robos bajan en 2020 por la pandemia (34.359) y en 2025 son 26,9 % menos que en 2024 (49.937 contra 68.304). Se desconoce si fue una baja real o un cambio en el

registro.

- El porcentaje de robos con arma cayó de 19,6 % (2017–2022) a 11,8 % (2024–2025). Es una deriva importante: el pasado se parece cada vez menos al presente.
- Los robos armados son más frecuentes de madrugada (16,1 % en el período de prueba) y de noche (13,6 %) que de mañana (6,8 %) o de tarde (10,9 %).
- En el período de prueba, el porcentaje con arma fue 31,6 % en la comuna 8, 20,1 % en la 4 y 17,9 % en la 9; en las demás comunas estuvo entre 5,0 % y 10,4 %.

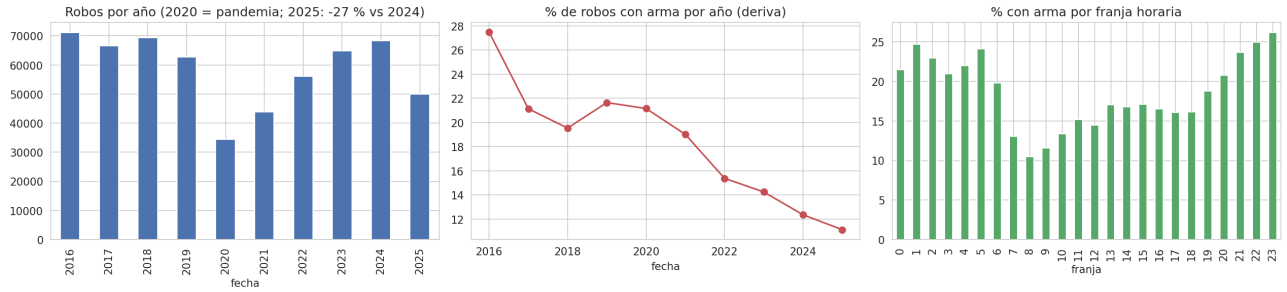


Figura 1. Robos por año, proporción con arma por año y por franja horaria.

Variable	Tipo	Descripción
comuna, mes, día de la semana	Categórica	One-Hot; se conocen de antemano (calendario y zona a patrullar).
franja (0–23)	Numérica + cíclica	Hora del hecho; seno y coseno para que 23 h y 0 h sean contiguas.
rate_12m	Numérica	Tasa de uso de arma de la celda en los últimos 365 días, suavizada hacia la tasa global.
rate_all	Numérica	Igual, con ventana expansiva desde 2016.
log_vol_12m	Numérica	log(1 + robos de la celda en los últimos 12 meses): captura el volumen.
uso_arma (objetivo)	Binaria	18,4 % de positivos; 19,3 % / 12,9 % / 11,5 % en entrenamiento / validación / prueba.

Tabla A. Variables utilizadas y variable objetivo. Todas se conocen antes del hecho.

3.2 Metodología (CRISP-DM)

Comprensión del negocio y de los datos: secciones 2 y 3.1. **Preparación:** se seleccionaron solo los robos y se armó una tabla diaria con una fila por comuna, franja y día. Las variables históricas usan únicamente información hasta el día anterior (con suavizado bayesiano para que las celdas con pocos casos no den valores extremos). Se eliminaron subtipo y uso_moto, que solo se conocen después del robo, y también latitud, longitud y barrio. Un test automático recalcula a mano las cinco variables históricas (rate_all, rate_12m, log_vol_12m, armados y volumen diarios) para 43 robos y verifica que solo usen hechos anteriores al día del evento.

Validación temporal. Los datos se dividieron por fecha: entrenamiento hasta el 16/06/2023 (361.363 robos), validación hasta el 27/07/2024 (77.359) y prueba hasta el 31/12/2025 (77.336). El año 2016 sirvió solo para que las ventanas de 12 meses tuvieran datos desde el principio. Además se repitió la evaluación en cinco pliegues expansivos (walk-forward). Semilla 42; el código está en el repositorio, con README e instrucciones de ejecución.

4. Modelado y evaluación

Algoritmos y criterios. Regresión Logística, Random Forest, XGBoost, LightGBM y una red neuronal densa (entrada → 32 → 8 → 1, con pérdida ponderada también en validación). Los hiperparámetros se eligieron en validación (PR-AUC): C = 0,1 en la Regresión Logística (grilla insensible: empate de PR-AUC) y 7 hojas en LightGBM. Como se ponderaron las clases, las probabilidades se calibraron con regresión isotónica y el umbral de decisión (≈ 0,17) se fijó maximizando F1 en validación, sin mirar la prueba.

Modelo	ROC-AUC	PR-AUC	Brier calibr.	Precision	Recall	F1	Fit (s)
Azar (prevalencia)	0,500	0,115	–	–	–	–	–
B1 Tasa histórica expansiva	0,679	0,235	–	–	–	–	–
B2 Tasa histórica 12 meses	0,691	0,240	–	–	–	–	–
Regresión Logística	**0,692**	**0,243**	**0,0952**	**0,251**	**0,440**	**0,319**	**0,8**
LightGBM	0,692	0,242	0,0952	0,257	0,429	0,322	4,6
XGBoost	0,692	0,242	0,0952	0,255	0,433	0,321	6,6
Random Forest	0,690	0,241	0,0953	0,259	0,421	0,321	29,9
Red neuronal (DNN)	0,692	0,241	0,0953	0,257	0,429	0,321	21,3

Tabla 1. Métricas en el período de prueba (n = 77.336; prevalencia 11,5 %). En negrita, el modelo elegido. Los tiempos de ajuste dependen de la máquina.

¿Las diferencias son reales? Se repitió la comparación 300 veces remuestreando semanas completas del período de prueba (75 semanas) y se analizó la diferencia de ROC-AUC de cada modelo contra la Regresión Logística. LightGBM, XGBoost y la red neuronal quedan a menos de 0,0002 y en todos los casos el intervalo incluye el cero: no se puede afirmar que sean mejores ni peores. Solo Random Forest es algo peor (−0,0026; IC95 [−0,0043; −0,0009]). La regla simple B2, sin ningún modelo, queda a −0,0018 (IC95 [−0,0040; +0,0005]): tampoco se distingue. En el walk-forward, la Regresión Logística y B2 tienen un ROC-AUC promedio casi idéntico (0,6596 y 0,6595). Casi toda la información útil está en el historial de cada combinación comuna × franja.

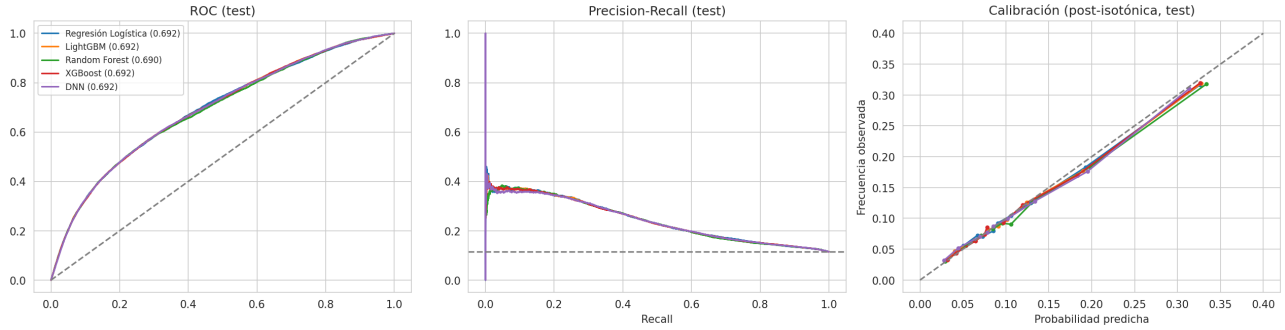


Figura 2. Curvas ROC, Precision-Recall y calibración (post-isotónica) en el período de prueba.

Elección final. Se elige la Regresión Logística: mismo desempeño que los demás, 26 veces más rápida que la red neuronal y 36 veces más que Random Forest, coeficientes interpretables (el historial rate_12m tiene odds ratio 1,36 por desvío estándar; las comunas 4 y 8 elevan el riesgo; ver anexo), menor riesgo de sobreajuste y calibración sencilla. Un modelo Poisson de LightGBM para la cuenta diaria de robos armados no mejora el pronóstico a un día respecto de «armados por día de los últimos 12 meses» (deviance

0,268 contra 0,265), por lo que solo se usó como estrategia secundaria.

5. Impacto en el negocio

Un modelo que estima P(arma | robo) no dice dónde habrá más robos armados: falta el volumen. Por eso se compararon estrategias para elegir 72 celdas con **una misma regla**: (i) el historial se congela al inicio del período (sin datos posteriores); (ii) el calendario futuro, que sí se conoce, se promedia; (iii) los empates se resuelven con un desempate aleatorio común. Se evaluó de dos formas con los robos armados reales: **ranking fijo** durante los 522 días de prueba y **ranking actualizado cada mes** (los modelos no se reentrenan; solo se actualizan sus variables históricas). La principal (Regresión Logística × volumen) se designó antes de calcular coberturas, pero la prueba ya se había explorado antes: la comparación es descriptiva; las otras son exploratorias.

Estrategia de priorización	Cobertura (fijo)	IC95 (fijo)	Δ vs armados 12m, pp (fijo)	Cobertura (mensual)	Δ vs armados 12m, pp (mensual)
Azar (2.000 sorteos)	20,0 %	[16,1; 24,3]	–	≈ 20,0 %	–
Volumen total de robos (12m)	39,8 %	[38,8; 40,9]	−11,90 [−13,21; −10,62]	40,3 %	−12,28 [−13,54; −11,01]
Tasa histórica (12m)	44,3 %	[42,8; 45,7]	−7,43 [−8,36; −6,46]	45,5 %	−7,04 [−7,96; −6,12]
Modelo: solo P(arma | robo), LR	45,1 %	[43,8; 46,5]	−6,61 [−7,62; −5,61]	45,6 %	−6,97 [−7,96; −5,96]
Armados de los últimos 12 meses	51,7 %	[50,4; 53,0]	0,0	52,6 %	0,0
Modelo: P × volumen, LR (principal)	**52,2 %**	**[50,8; 53,6]**	**+0,47 [+0,02; +0,92]**	**52,7 %**	**+0,11 [−0,37; +0,59]**
Modelo: P × volumen, LightGBM	52,3 %	[51,0; 53,5]	+0,53 [+0,11; +0,93]	52,9 %	+0,34 [−0,06; +0,72]
Poisson (cuenta esperada, LightGBM)	52,3 %	[50,9; 53,5]	+0,52 [+0,02; +1,03]	52,5 %	−0,11 [−0,51; +0,29]
Techo teórico (oráculo)	53,5 %	[52,1; 54,7]	–	62,4 %	–

Tabla 2. Cobertura de robos con arma al priorizar el 20 % de las celdas comuna × franja (IC95 por bootstrap de semanas). El oráculo conoce los resultados de antemano; con ranking mensual cubre 62,4 %. Resultados completos en el anexo.

Lectura.

- Elegir zonas y horarios con un criterio basado en datos cubre más del doble que hacerlo al azar: 52 % contra 20 %.
- Ordenar solo por la probabilidad de que un robo sea con arma deja 6,6 puntos por debajo de la regla simple: la proporción de armados no basta, hay que sumar cuántos robos ocurren.
- Al sumar el volumen, la Regresión Logística pasa a 52,2 % contra 51,7 % de la regla simple: +0,47 pp, con un límite inferior del intervalo pegado a cero (unos 42 robos armados en 522 días). Con ranking mensual la diferencia es +0,11 pp [−0,37; +0,59], indistinguible de cero. Ningún modelo secundario supera a la regla simple por más de 0,6 pp.
- El techo con ranking fijo es 53,5 %: la estrategia principal queda a 1,25 pp y la regla simple a 1,72 pp. Casi todo lo capturable ya es visible en el historial; el techo mensual (62,4 %) supone conocer el futuro de cada mes y no es alcanzable con estas variables.

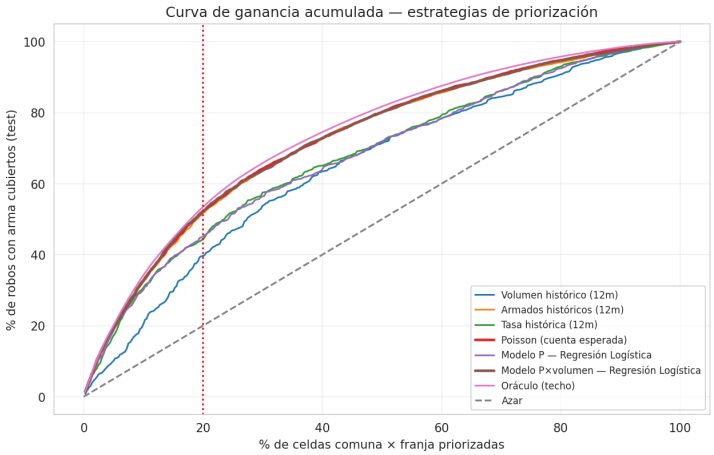


Figura 3. Curva de ganancia acumulada de las estrategias de priorización (ranking fijo).

Beneficios, escalabilidad y pasos futuros. El sistema es liviano (entrena en segundos y corre en cualquier equipo), explicable y escalable a otras jurisdicciones o delitos con el mismo esquema. La regla simple no requiere modelo y es la base más barata de operar. Próximos pasos: tablero con ranking mensual, piloto con zonas de control y umbrales por territorio.

6. Riesgos, ética y limitaciones

- **Subregistro y sesgo de medición.** Los datos son denuncias, no delitos: el modelo aprende dónde se denuncia y registra, no la realidad criminal completa.
- **Bucle de retroalimentación.** Más patrullaje genera más registros en esa zona y, con ello, más riesgo estimado. Mitigación: piloto con zonas de control, rotación parcial del ranking y reentrenamiento auditado.
- **Equidad.** Con un umbral único, el recall es 0 en 8 de 15 comunas, 0,84 en la comuna 4 y 0,97 en la 8: el clasificador actúa casi como un identificador de comuna. Deben fijarse metas o umbrales por territorio y comunicar riesgo por celda, no por personas ni barrios.

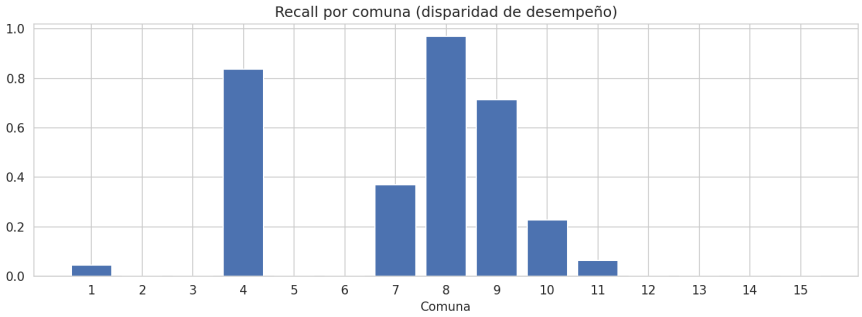


Figura 4. Recall por comuna con un umbral único (período de prueba).

- **Privacidad.** Solo datos públicos y agregados, sin datos personales. Se descartaron coordenadas y barrio a propósito para evitar reidentificación y vigilancia hiperlocalizada.
- **Deriva y calidad de datos.** La proporción de armados bajó de 19,6 % a 11,8 %; 2020 es atípico y 2025 registra 26,9 % menos robos. Se requiere monitoreo mensual y recalibración.
- **Alcance de la evaluación.** Hay un único período de prueba de 18 meses; la cobertura es retrospectiva y todo resultado es asociación predictiva, no causal. Los modelos del

ranking mensual no se reentrenaron.

- **Gobernanza.** Responsable humano de la decisión, bitácora de versiones del modelo, auditoría trimestral de sesgos y publicación de métricas por comuna.

7. Conclusiones y recomendaciones

Conclusiones.

- Hay estructura predecible, pero se concentra en el historial de cada comuna × franja: un promedio bien construido iguala a cualquier modelo.
- La red neuronal no justifica su costo ni su opacidad.
- El valor del proyecto está en la decisión: priorizar el 20 % de las celdas por cantidad esperada de robos armados cubre cerca del 52 % de ellos, 2,6 veces más que el azar. Sobre la regla simple de armados de 12 meses, el modelo agrega +0,47 pp con ranking fijo (límite inferior del IC95 casi en cero) y +0,11 pp con ranking mensual (no distinguible de cero).
- Validar en el tiempo, aplicar la misma regla de evaluación a todas las estrategias y comparar contra baselines evitó presentar una mejora que no existía.

Recomendaciones. (a) Operar con el ranking de armados de los últimos 12 meses, actualizado cada mes; mantener la Regresión Logística calibrada × volumen como alternativa de control. (b) Monitorear Brier, prevalencia y cobertura por comuna. (c) Definir umbrales por territorio antes de operar. (d) Evaluar el impacto causal con un piloto de despliegue escalonado con zonas de control. (e) Asignar un responsable humano y una auditoría trimestral de sesgos.

Anexo A. Resultados complementarios

Estrategia	Rol	Cobertura fija	IC95 (fijo)	Cobertura mensual
Volumen histórico (12m)	Baseline sin ML	39,8 %	[38,8; 40,9]	40,3 %
Armados históricos (12m)	Baseline sin ML	51,7 %	[50,4; 53,0]	52,6 %
Tasa histórica (12m)	Baseline sin ML	44,3 %	[42,8; 45,7]	45,5 %
Poisson (cuenta esperada)	Secundaria (exploratoria)	52,3 %	[50,9; 53,5]	52,5 %
Modelo P — Regresión Logística	Secundaria (exploratoria)	45,1 %	[43,8; 46,5]	45,6 %
Modelo P×volumen — Regresión Logística	PRINCIPAL (designada)	52,2 %	[50,8; 53,6]	52,7 %
Modelo P — LightGBM	Secundaria (exploratoria)	45,9 %	[44,4; 47,4]	45,7 %
Modelo P×volumen — LightGBM	Secundaria (exploratoria)	52,3 %	[51,0; 53,5]	52,9 %
Modelo P — Random Forest	Secundaria (exploratoria)	45,6 %	[44,2; 47,0]	45,8 %
Modelo P×volumen — Random Forest	Secundaria (exploratoria)	52,0 %	[50,8; 53,2]	52,7 %
Modelo P — XGBoost	Secundaria (exploratoria)	45,9 %	[44,4; 47,3]	45,9 %
Modelo P×volumen — XGBoost	Secundaria (exploratoria)	51,8 %	[50,5; 53,1]	52,8 %
Modelo P — DNN	Secundaria (exploratoria)	45,8 %	[44,4; 47,1]	46,2 %
Modelo P×volumen — DNN	Secundaria (exploratoria)	52,2 %	[50,8; 53,5]	52,8 %
Oráculo (techo)	Techo teórico	53,5 %	[52,1; 54,7]	62,4 %

Tabla A2. Cobertura completa del top-20 % de celdas, con ranking fijo y actualizado mensualmente. La estrategia principal es la de referencia; las demás son exploratorias.

Estrategia	Δ fijo vs armados 12m, pp [IC95]	Δ mensual vs armados 12m, pp [IC95]
Poisson (cuenta esperada)	+0,52 [+0,02; +1,03]	−0,11 [−0,51; +0,29]
Modelo P×volumen — Regresión Logística	+0,47 [+0,02; +0,92]	+0,11 [−0,37; +0,59]
Modelo P×volumen — LightGBM	+0,53 [+0,11; +0,93]	+0,34 [−0,06; +0,72]
Modelo P×volumen — Random Forest	+0,25 [−0,17; +0,67]	+0,09 [−0,29; +0,48]
Modelo P×volumen — XGBoost	+0,09 [−0,39; +0,57]	+0,25 [−0,15; +0,67]
Modelo P×volumen — DNN	+0,47 [+0,13; +0,82]	+0,27 [−0,08; +0,62]

Tabla A3. Diferencia de cobertura contra la regla de armados de 12 meses (bootstrap de semanas; IC95 sin ajuste por multiplicidad).

Walk-forward (5 pliegues). ROC-AUC promedio: Regresión Logística 0,6596 (desvío 0,027), LightGBM 0,6609 (0,027) y regla B2 0,6595 (0,025). El desempeño sube con los años porque la prevalencia baja y el historial se vuelve más informativo.

Empates. Tras la calibración isotónica y por el uso de conteos enteros, algunas estrategias generan empates; en el corte del top-20 % hay como máximo 3 celdas empatadas y se resuelven con un desempate aleatorio común.

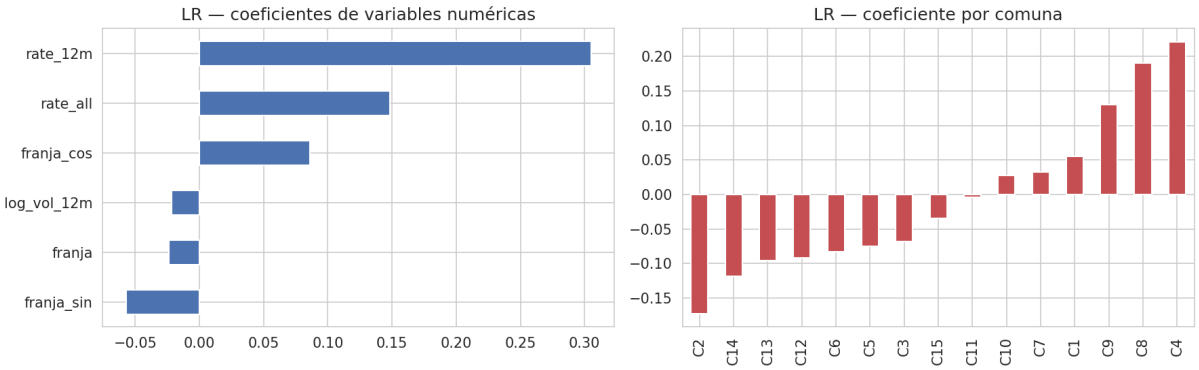


Figura A1. Coeficientes de la Regresión Logística (variables numéricas estandarizadas y comuna).