# Trabajo Final Integrador

## Predicción del uso de arma en robos de la Ciudad de Buenos Aires para priorizar el patrullaje preventivo

---

**Diplomatura en Ciencia de Datos y Análisis Avanzado**

Proyecto Final Integrador

**Equipo:** Grupo 29

**Integrantes:**

Carlos Amigo

Vanina Rieznik

Luis Cortez

Octubre de 2026

Repositorio de código: https://github.com/charlyfriend68/DiploData

# 1. Resumen ejecutivo

**Problema.** La Ciudad de Buenos Aires dispone de recursos de patrullaje limitados. Los robos con arma son los de mayor gravedad, y su proporción cambia mucho según el territorio y la hora. La decisión operativa es: En qué combinaciones *comuna* × *franja horaria* (15 × 24 = 360 celdas) se concentraría la presencia preventiva?.

**Solución.** A partir de 592.817 robos registrados entre 2016 y 2025 se construyó un sistema de priorización que usa solo información disponible *antes* del hecho (zona, hora, día, mes e historial de la celda). Se compararon cinco modelos

- Regresión Logística
- Random Forest
- XGBoost, LightGBM
- Una red neuronal

contra baselines simples, con validación estrictamente temporal.

**Resultados clave.**

- Priorizando el 20 % de las celdas (72 de 360), el modelo cubre el 53,1 % de los robos con arma del período de prueba. Si se eligieran esas 72 combinaciones al azar, solo se cubriría un 20 %, y si se eligieran mirando únicamente dónde hubo más robos en total, se cubriría un 39,6 %.
- El mejor baseline no estadístico, "seguir los robos armados de los últimos 12 meses", ya cubre 51,7 %. El modelo lo supera por **+1,4 puntos**, una mejora pequeña pero estadísticamente robusta.
- A nivel de cada robo, la capacidad de discriminación es moderada (ROC-AUC 0,69; PR-AUC 0,24 contra 0,11 del azar) y **es la misma para los cinco modelos**. La red neuronal no aporta valor y es 35 veces más lenta que la Regresión Logística.

**Recomendación.** Operar con una Regresión Logística calibrada combinada con el volumen esperado de robos (o, por simplicidad, con el ranking de armados de 12 meses), reentrenada y recalibrada cada mes, y medir el efecto real del patrullaje con un piloto con zonas de control antes de escalar.

## 2. Definición del problema y relevancia

**Contexto y motivación.** El patrullaje preventivo es un recurso escaso: no se puede cubrir toda la ciudad a toda hora. Un criterio explícito y auditable para asignarlo mejora la eficiencia y permite explicar las decisiones. La experiencia, habiendo trabajado en el ministerio de seguridad de CABA, (y la lógica misma), indica que concentrar la presencia en pocos lugares y momentos específicos, reduce el delito de forma significativa.

**Objetivo medible.** Seleccionar el 20 % de las combinaciones comuna × franja que maximice la **cobertura de robos con arma**, es decir, la proporción de robos armados ocurridos en las celdas priorizadas. Se evalúa sobre un período futuro que el modelo no vio.

**KPI principal:** cobertura del top-20 % de celdas.

**KPIs secundarios:** ROC-AUC y PR-AUC (por la fuerte asimetría de clases), recall por comuna (equidad) y estabilidad temporal.

**Hipótesis.**

- **H1**: Hay estructura predecible en el riesgo por zona y hora.
- **H2**: Un modelo flexible supera al promedio histórico.
- **H3**: Combinar la probabilidad de uso de arma con el volumen de robos es mejor que usar solo la probabilidad.

Los resultados confirman **H1** y **H3,** y **no** confirman **H2.**

**Restricciones.** Solo datos agregados y anónimos; sin información previa al hecho más allá de zona, calendario e historial; decisión humana final; resultados explicables para un equipo no técnico.

**Valor esperado.** En el período de prueba (522 días) hubo unos 8.900 robos con arma. Cada punto porcentual de cobertura equivale a casi 90 de ellos. Cubrir 53 % en lugar de 20 % significa concentrar la presencia donde ocurren cerca de 2.900 más. Cobertura no es lo mismo que delitos evitados: ese efecto requiere un diseño causal (sección 6).

## 3. Datos y metodología

### 3.1 Fuente y calidad de los datos

Se usaron los archivos públicos de delitos de la Ciudad (2016–2025): 1.387.622 registros, de los cuales 592.817 son robos (42,7 %). Se descartó el 0,9 % de los robos por falta de comuna (0,80 %) o de franja (0,16 %); su tasa de arma (17,0 %) es similar a la del resto (18,4 %), por lo que el descarte no sesga el resultado. Todas las filas tienen cantidad = 1.

**Conclusiones del análisis exploratorio:**

(i) La cantidad de robos por año baja en 2020, por la pandemia, y en 2025 es cerca de un 27 % menor que en 2024. Se desconoce todavía si esa baja fue real o si cambió la forma de registrar los hechos.

(ii) El porcentaje de robos con arma bajó mucho con los años, de alrededor de 19 % a alrededor de 11 %. Este cambio es muy importante: significa que el pasado se parece cada vez menos al presente, y eso afecta a todo el modelo que se armó.

(iii) Los robos con arma son más frecuentes de noche y de madrugada.

(iv) En el período de prueba, el porcentaje de robos con arma fue de 31,6 % en la comuna 8, 20,1 % en la 4 y 17,9 % en la 9, mientras que en la mayoría de las demás comunas estuvo entre 5 % y 8 %.

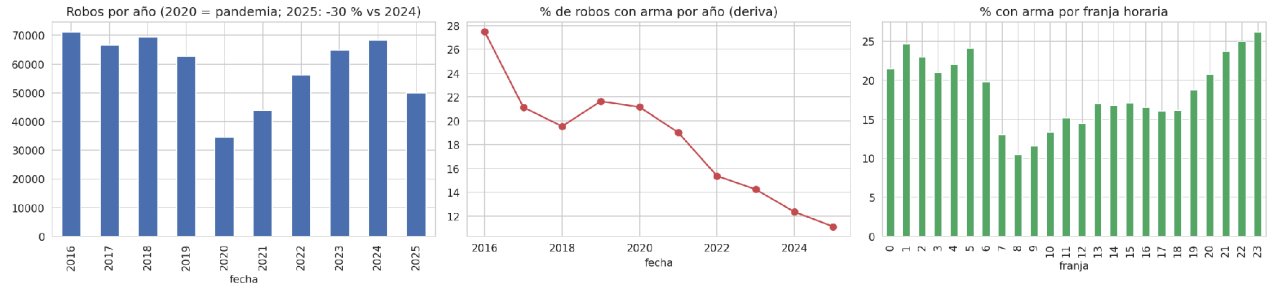



*Figura 1. Robos por año, proporción con arma por año y por franja horaria.*

**Variables clave.** Todas se conocen antes del hecho; el objetivo es “uso_arma”.

| Variable | Tipo | Descripción |
|---|---|---|
| comuna, mes, día de la semana | Categórica | Codificación One-Hot; se conocen de antemano (calendario y zona a patrullar). |
| franja (0–23) | Numérica + cíclica | Hora del hecho; seno y coseno para que 23 h y 0 h sean contiguas. |
| rate_12m | Numérica | Tasa de uso de arma de la celda en los últimos 365 días, suavizada hacia la tasa global. |
| rate_all | Numérica | Igual, con ventana expansiva desde 2016. |
| log_vol_12m | Numérica | log(1 + robos de la celda en los últimos 12 meses): captura el volumen. |
| uso_arma (objetivo) | Binaria | 18,4 % de positivos; 19,3 % / 12,9 % / 11,5 % en entrenamiento / validación / prueba. |

*Tabla A. Variables utilizadas y variable objetivo.*

## 3.2 Metodología (CRISP-DM)

**Comprensión del negocio y de los datos:** secciones 2 y 3.1. **Preparación de los datos:** (a) Se seleccionaron solo los robos y se armó una tabla diaria en la que cada fila es una combinación de comuna, horario y día. (b) Se crearon variables que usan únicamente información hasta el día anterior, para que el modelo nunca “vea” el futuro: la

proporción de robos con arma de los últimos 365 días (rate_12m, ajustada para que las combinaciones con pocos casos no den valores extremos), la proporción de toda la historia disponible hasta ese día (rate_all) y la cantidad de robos de los últimos 12 meses (log_vol_12m). Además, se incluyeron como variables la comuna, el día de la semana, el mes y la hora. Se eliminan las variables subtipo y uso_moto, porque solo se conocen después de que ocurre el robo, y también latitud, longitud y barrio. **Validación temporal.** Los datos se dividieron por fecha y no al azar, para entrenar con el pasado y probar con el futuro. El entrenamiento llega hasta el 16/06/2023 (361.363 robos), la validación hasta el 27/07/2024 (77.359) y la prueba hasta el 31/12/2025 (77.336). El año 2016 se usó solo para que las proporciones de los últimos 12 meses tuvieran datos desde el principio. También se repitió la evaluación cinco veces, avanzando en el tiempo cada vez (*walk-forward*). Para que el trabajo se pueda repetir, se fijó un valor inicial (semilla 42) y se cargó el código al repositorio.

## 4. Modelado y evaluación

**Algoritmos y criterios.** Regresión Logística, Random Forest, XGBoost, LightGBM y una red neuronal densa (entrada → 32 → 8 → 1, pérdida ponderada también en validación). Los hiperparámetros se eligieron **en validación** (PR-AUC): la fuerza de regularización de la Regresión Logística y el tamaño de los árboles de LightGBM. Dado que se ponderaron las clases, las probabilidades se calibraron con regresión isotónica y el umbral de decisión se fijó maximizando F1 en validación, sin mirar la prueba.

**Comparación (período de prueba).** Se incluyeron dos baselines que no usan aprendizaje automático: la tasa histórica expansiva (B1) y la de 12 meses (B2).

| Modelo | ROC-AUC | PR-AUC | Brier calibr. | Precision | Recall | F1 | Fit (s) |
|---|---|---|---|---|---|---|---|
| Azar (prevalencia) | 0,500 | 0,115 | – | – | – | – | – |
| B1 Tasa histórica expansiva | 0,679 | 0,235 | – | – | – | – | – |
| B2 Tasa histórica 12 meses | 0,690 | 0,240 | – | – | – | – | – |
| **Regresión Logística** | **0,692** | **0,243** | **0,0952** | **0,251** | **0,440** | **0,319** | **0,6** |
| LightGBM | 0,692 | 0,242 | 0,0952 | 0,258 | 0,429 | 0,322 | 3,8 |
| XGBoost | 0,692 | 0,242 | 0,0952 | 0,255 | 0,433 | 0,321 | 5,6 |
| Random Forest | 0,690 | 0,241 | 0,0953 | 0,259 | 0,421 | 0,321 | 27,6 |
| Red neuronal (DNN) | 0,692 | 0,241 | 0,0953 | 0,257 | 0,429 | 0,321 | 18,8 |

*Tabla 1. Métricas en el período de prueba (n = 77.336; prevalencia 11,5 %). En negrita, el modelo elegido.*

**¿Las diferencias son reales?** Para saberlo, se repitió la comparación 300 veces con muestras armadas con semanas completas del período de prueba, y se analizó la diferencia en ROC-AUC de cada modelo contra la Regresión Logística. LightGBM, XGBoost y la red neuronal quedan a menos de 0,002 de diferencia, y en todos los casos

el margen de error incluye el cero: no se puede afirmar que sean mejores ni peores. Solo Random Forest es un poco peor (−0,0026). La regla simple B2, que usa la proporción de robos con arma de los últimos 12 meses sin ningún modelo, queda a −0,0018 de la Regresión Logística (margen de error de −0,004 a +0,0005): tampoco se distingue. En la evaluación por tramos, la Regresión Logística y B2 tienen un ROC-AUC promedio casi idéntico (0,6596 y 0,6595). Es decir, casi toda la información útil está en el historial de cada combinación de comuna y horario.

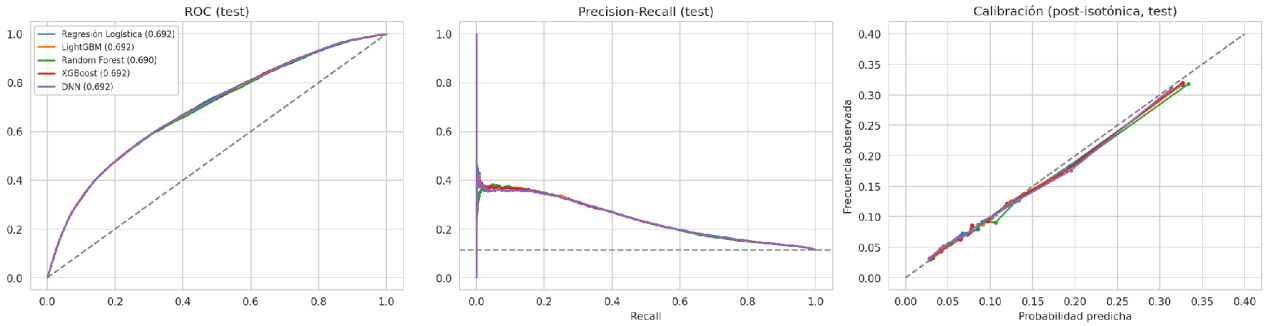



*Figura 2. Curvas ROC, Precision-Recall y calibración (post-isotónica) en el período de prueba.*

**Elección final.** Se elige la **Regresión Logística**: igual desempeño que los demás, 34 a 50 veces más rápida que la red neuronal y Random Forest, coeficientes interpretables, menor riesgo de sobreajuste y calibración sencilla.

## 5. Impacto en el negocio

Un modelo que estima la probabilidad de arma *dado un robo* no dice dónde habrá **más robos armados**: falta el volumen. Por eso se compararon estrategias para elegir 72 celdas, todas con información previa al período de prueba (ranking fijo, como en un despliegue real) y evaluadas con los robos armados reales.

| Estrategia de priorización | Cobertura | IC95 | Δ vs armados 12m (pp) |
|---|---|---|---|
| Azar (2.000 sorteos) | 20,0 % | [16,1; 24,4] | – |
| Volumen total de robos (12m) | 39,6 % | [38,6; 40,7] | −12,1 |
| Tasa histórica (12m) | 44,3 % | [42,9; 45,6] | −7,4 |
| Modelo: solo P(arma \| robo), LR | 45,9 % | [44,5; 47,3] | −5,8 |
| Armados de los últimos 12 meses | 51,7 % | [50,4; 53,0] | 0,0 |
| **Modelo: P × volumen, LR** | **53,1 %** | **[51,8; 54,5]** | **+1,4 [+0,8; +1,9]** |
| Poisson (cuenta esperada, LightGBM) | 53,3 % | [52,0; 54,5] | +1,6 [+1,1; +2,0] |
| Techo teórico (oráculo) | 53,5 % | [52,1; 54,7] | +1,7 |

*Tabla 2. Cobertura de robos con arma al priorizar el 20 % de las celdas comuna × franja (IC95 por bootstrap semanal).*

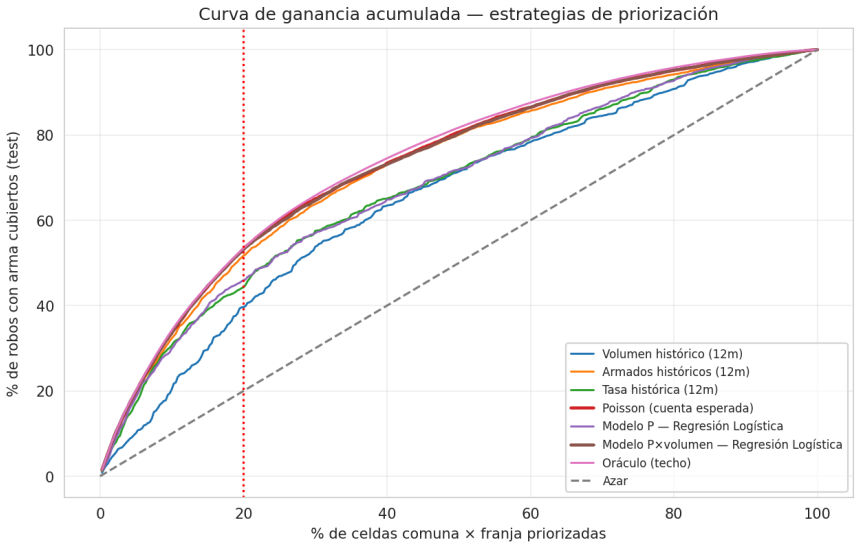



*Figura 3. Curva de ganancia acumulada de las estrategias de priorización.*

**Lectura.** (1) Elegir las zonas y horarios con un criterio basado en datos cubre más del doble que elegirlos al azar: 53 % contra 20 %.

(2) El 44 % que se mostró en el avance anterior solo se comparaba contra el azar. Al compararlo con una regla simple y razonable (las zonas con más robos con arma en los últimos 12 meses), un modelo que ordena solo por la probabilidad de que un robo sea con arma queda 5,8 puntos por debajo.

(3) Cuando el modelo suma la cantidad de robos de cada zona, supera a esa regla simple y queda a unos 0,4 puntos del máximo que se puede lograr con un ranking armado de antemano. Es decir, queda muy poco margen para mejorar.

**Beneficios, escalabilidad y pasos futuros.** El sistema es liviano (entrena en segundos, corre en cualquier equipo), explicable y escalable a otras jurisdicciones o delitos con el mismo esquema. Próximos pasos: tablero con ranking mensual, piloto con zonas de control, y umbrales por territorio.

## 6. Riesgos, ética y limitaciones

- **Subregistro y sesgo de medición.** Los datos son denuncias, no delitos: el modelo aprende dónde se denuncia y registra, no la realidad criminal completa.
- **Bucle de retroalimentación.** Más patrullaje genera más registros en esa zona y, con ello, más riesgo estimado. Mitigación: piloto con zonas de control, rotación parcial del ranking y reentrenamiento auditado.
- **Equidad.** Con un umbral único, el recall es 0 en 8 de 15 comunas y supera 0,8 en las comunas 4 y 8: el modelo actúa como un clasificador de comuna. Debe fijarse

metas o umbrales por territorio y comunicar riesgo por celda, no por personas ni barrios.

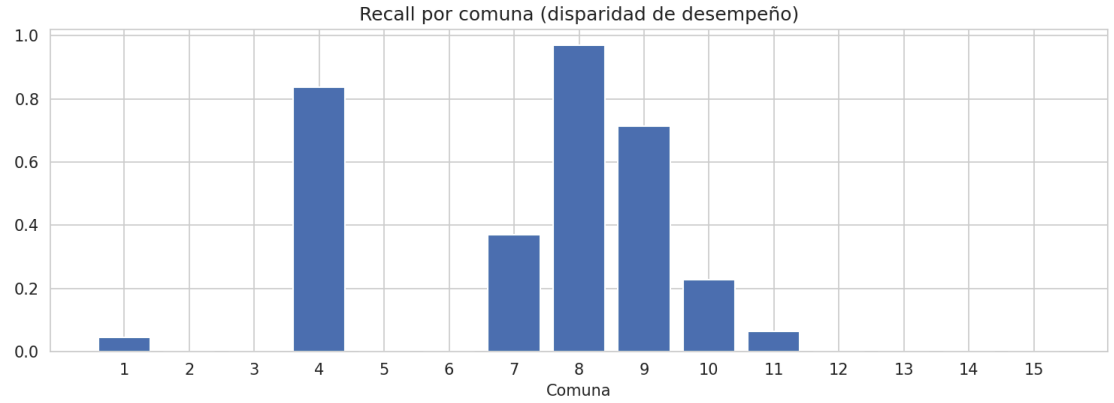



*Figura 4. Recall por comuna con un umbral único (período de prueba): disparidad de desempeño entre territorios.*

- **Privacidad.** Solo datos públicos y agregados, sin datos personales. Se descartaron coordenadas y barrio a propósito para evitar reidentificación y vigilancia hiperlocalizada.
- **Deriva y calidad de datos.** La proporción de armados bajó de 19 % a 11 %; 2020 es atípico y 2025 registra 27 % menos robos. Se requiere monitoreo mensual y recalibración. Todo resultado es asociación predictiva, no causal.

## 7. Conclusiones y recomendaciones

**Conclusiones.**

1. Hay estructura predecible, pero se concentra en el historial de cada comuna × franja: un promedio bien construido casi iguala a cualquier modelo.
2. La red neuronal no justifica su costo ni su opacidad. (3) El valor del proyecto está en la **decisión**: priorizar el 20 % de celdas por cantidad esperada de robos armados cubre 53 % de ellos, 2,6 veces más que el azar. (4) Corregir la fuga de información, validar en el tiempo y comparar contra baselines evitó presentar una mejora que no existía.

**Recomendaciones.** (a) Desplegar Regresión Logística calibrada × volumen esperado, con reentrenamiento mensual. (b) Monitorear Brier, prevalencia y cobertura por comuna. (c) Definir umbrales por territorio antes de operar. (d) Evaluar el impacto causal con un piloto de despliegue escalonado con zonas de control. (e) Asignar un responsable humano y una auditoría trimestral de sesgos.